Veri Sözlüğü (Data Dictionary)

1. Genel Bilgiler

Bu bölümde temiz veri setindeki sütunların ne anlama geldiği, hangi veri türünde olduğu ve hangi değerleri alabileceği açıklanmıştır.

- Dosya adı: `harcamalar_temiz.csv`
- Kayıt sayısı: 1.491
- Sütun sayısı: 3
- Tarih aralığı: 2023-01-01 – 2025-12-31
- Karakter kodlaması: UTF-8
- Sütun ayırıcı: virgül (`,`)
- Ondalık ayırıcı: nokta (`.`)
- Kayıtlar tarihe göre sıralıdır ve her satır bir harcamayı gösterir.

2. Sütunlar

Sütun Adı	Açıklama	Veri Türü	Format	Örnek	Zorunlu
`Tarih`	Harcamanın yapıldığı gün	Tarih (datetime)	`YYYY-MM-DD`	`2024-03-15`	Evet
`Tutar`	Harcama tutarı (TL)	Ondalıklı sayı (float)	İki ondalık basamak	`486.25`	Evet
`Kategori`	Harcamanın türü	Metin (string)	Kategori listesindeki ad	`Market`	Evet

3. Sütunların Açıklaması

Tarih: Harcamanın yapıldığı günü gösterir, saat bilgisi yoktur. 1 Ocak 2023 ile 31 Aralık 2025 arasındaki tarihleri içerir. Aylık analiz (FR-04) ve tahmin (FR-06) yapılırken harcamalar bu sütuna göre aylara ayrılacaktır.

Tutar: Harcamanın TL cinsinden tutarıdır. Tüm değerler sıfırdan büyüktür. En küçük harcama 24,55 TL, en büyük harcama 8.563,06 TL'dir. Toplam ve ortalama harcama (FR-02) bu sütundan hesaplanır.

Kategori: Harcamanın hangi türe ait olduğunu gösterir. Kategori bazında analiz (FR-03) bu sütuna göre yapılır. Alabileceği değerler aşağıdaki tabloda verilmiştir.

4. Kategori Değerleri

Kategori	Açıklama	Kayıt Sayısı
`Market`	Gıda ve günlük ihtiyaç alışverişleri	447
`Ulaşım`	Yakıt, toplu taşıma, taksi vb.	358
`Restoran`	Restoran, kafe ve yemek siparişleri	306
`Fatura`	Elektrik, su, doğalgaz, internet ve telefon faturaları	141
`Eğlence`	Sinema, konser, etkinlik vb.	105
`Giyim`	Kıyafet ve ayakkabı alışverişleri	85
`Sağlık`	Eczane ve sağlık harcamaları	34
`Diğer`	Ham veride kategorisi eksik olan harcamalar	15

5. Ham Veri ve Temiz Veri Karşılaştırması

Sütun	Ham Veri (`harcamalar_ham.csv`)	Temiz Veri (`harcamalar_temiz.csv`)
`Tarih`	Metin olarak tutuluyor; üç farklı format var; bazı değerler eksik	Tarih türünde; sadece `YYYY-MM-DD`; eksik değer yok
`Tutar`	Metin olarak tutuluyor; nokta veya virgül kullanılmış; bazılarında `TL` eki var; bazı değerler eksik	Sayısal; ondalık ayırıcı nokta; eksik değer yok
`Kategori`	Büyük-küçük harf ve boşluk farkları var; bazı değerler eksik	Kategori adları düzeltilmiş; eksikler `Diğer` yapılmış
Kayıtlar	1.539 kayıt; tekrar eden kayıtlar var; sıralama karışık	1.491 kayıt; tekrar yok; tarihe göre sıralı

6. Kullanırken Dikkat Edilmesi Gerekenler

- Dosya Python'da `pd.read_csv("harcamalar_temiz.csv", parse_dates=["Tarih"])` ile okunursa `Tarih` sütunu doğrudan tarih türünde gelir.
- Aynı gün içinde birden fazla harcama olabilir. Aylık toplamlar için veri aylara göre gruplanmalıdır.
- `Diğer` gerçek bir harcama türü değildir, kategorisi bilinmeyen harcamaları gösterir. Kategori karşılaştırmasında bu durum belirtilmelidir.
- Fiyat artışı nedeniyle tutarlar yıllar içinde yükseliyor. Farklı yıllar karşılaştırılırken bu göz önünde bulundurulmalıdır.